UNIVERSIDADE FEDERAL DO PARÁ
INSTITUTO DE CIÊNCIAS EXATAS E NATURAIS
FACULDADE DE COMPUTAÇÃO
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

PROGRAMAÇÃO PARALELA

Prof. Josivaldo Araújo
josivaldo@ufpa.br



Unidade 02:
Arquiteturas Paralelas e Modelos Hierárquicos

Sumário

1. Motivação e Objetivos
2. Introdução
3. Classificações e Terminologias
    3.1. Classificação de *Flynn*
    3.2. Classificação de Duncan
4. Tipos de Comunicação
    4.1. Arquitetura com Memória Compartilhada
        a) UMA (*Uniform Memory Access*)
        b) NUMA (*Non-Uniform Memory Access*)
    4.2. Arquitetura com Memória Distribuída
        4.2.1. Síncrono
        4.2.2. Assíncrono
        4.2.3. NORMA (*Non-Remote Memory Access*)
5. Coerência de Cache
    5.1. Outras Classificações
    5.2. Aceleradores
6. Conclusão
7. Referências

Motivação

- Definir os tipos de comunicações de acordo com a arquitetura utilizada;
- Descrever os modelos de arquiteturas, classificando-as segundo os conceitos de **fluxo de instrução** e **fluxo de dados**
- Apresentar as principais hierarquias de memórias, assim como, os problemas de cache que podem resultar de cada modelo.

Objetivos

- Compreender o estilo de comunicação e programação tendo como base a arquitetura disponível;
- Definir as diferentes taxonomias segundo as arquiteturas existentes.
  - Taxonomia de *Flynn* x Taxonomia de *Duncan*;
- Compreender as diferentes formas de se compartilhar (ou não) a memória em algumas arquiteturas;
  - Classificar as hierarquias de memórias e as vantangens e desvantagens que são proporcionadas;
  - Apresentar soluções para os problemas de coerência de cache;

Introdução

- O motivo pelo qual os sistemas computacionais tem conseguido manter um ritmo de crescimento nos últimos anos é devido à exploração e à concepção de arquiteturas paralelas;
- Arquiteturas Paralelas ou de Alto Desempenho são baseadas na utilização de múltiplas unidades de processamento;
- Atualmente, estão sendo explorados diferentes níveis de paralelismo, principalmente, na área de IA;
  - ✓ CPUs (*Central Processing Unit*);
  - ✓ GPUs (*Graphics Processing Unit*);
  - ✓ TPUs (*Tensor Processing Unit*);

Introdução

COMPARAÇÃO: CPU vs GPU vs TPU

Arquitetura e Casos de Uso

	CPU Unidade Central de Processamento	GPU Unidade de Processamento Gráfico	TPU Unidade de Processamento Tensorial
Uso Principal	Sistemas Operacionais Aplicações Gerais	Renderização Gráfica Matemática Paralela, IA	Aprendizado de Máquina em Hiperescala (Treinamento/Inferência)
Tipo de Processamento	Serial (Sequencial)	Paralelo (Milhares de Núcleos)	Paralelismo Extremo de Tensores/Matrizes
Flexibilidade	Alta (Uso Geral)	Alta (Suporte a Frameworks de IA/Código Personalizado)	Baixa (Otimizado para Grafos Específicos)
Ecossistema	Universal (x86, ARM)	Amplo (NVIDIA CUDA, OpenCL)	Restrito (Google Cloud, TensorFlow, JAX)

Os TPUs são otimizados especificamente para fluxos de trabalho de redes neurais, enquanto CPUs e GPUs são processadores de uso mais geral.

Sumário

1. Motivação e Objetivos
2. Introdução
3. Classificações e Terminologias
    - 3.1. Classificação de *Flynn*
    - 3.2. Classificação de Duncan
4. Tipos de Comunicação
    - 4.1. Arquitetura com Memória Compartilhada
        - a) UMA (*Uniform Memory Access*)
        - b) NUMA (*Non-Uniform Memory Access*)
    - 4.2. Arquitetura com Memória Distribuída
        - 4.2.1. Síncrono
        - 4.2.2. Assíncrono
        - 4.2.3. NORMA (*Non-Remote Memory Access*)
5. Coerência de Cache
    - 5.1. Outras Classificações
    - 5.2. Aceleradores
6. Conclusão
7. Referências

Classificações e Terminologias

- Para melhor entender a concepção das diferentes arquiteturas paralelas, pode-se utilizar técnicas de classificação;
- Essas técnicas podem ser baseadas na relação que existe entre o **fluxo de instrução** e o **fluxo de dados**;
- Podem ser classificadas, também, em termos de arquiteturas paralelas quanto aos **modelos de programação** correspondentes;
    - ✓ Que pode ser realizada segundo o **compartilhamento de memória**;

Classificações e Terminologias

- O Paralelismo em múltiplos níveis acaba sendo a força impulsionadora do projeto de computadores;
- Existem basicamente dois tipos de paralelismo em aplicações:
  - Paralelismo a nível de **DADOS**: surge porque existem muitos itens de dados que podem ser operados ao mesmo tempo;
  - Paralelismo a nível de **TAREFA**: surge porque são criadas tarefas que podem operar de modo independente e principalmente em paralelo;

Classificações e Terminologias

- O hardware do computador pode explorar esses dois tipos de paralelismo de aplicações de quatro modos diferentes;
- Esses quatro modos de o hardware suportar o paralelismo a nível de dados e o paralelismo a nível de tarefas têm mais de 50 anos.
- Quando *Michael Flynn* estudou os esforços de computação paralela nos ano 70, encontrou uma classificação simples, que é usada até hoje;

"*Some computer organizations and their effectiveness*", IEEE Transactions on Computers, vol. C-21, pp. 948-960, 1972.

Classificações e Terminologias

3.1. Classificação de Flynn

- *Michael Flynn*, em 1972, classificou os computadores através da análise do **Fluxo de Instruções** e do **Fluxo de Dados**.
- Essa classificação ficou conhecida como a *Taxonomia de Flynn*.

Fluxo de Instruções \ Fluxo de Dados	Único	Múltiplo
Único	SISD Single Instruction Single Data Instrução Simples de Dados Simples	SIMD Single Instruction Multiple Data Instrução Simples de Múltiplos Dados
Múltiplo	MISD Multiple Instruction Single Data Instrução Múltiplas de Dados Simples	MIMD Multiple Instruction Multiple Data Instrução Múltiplas de Dados Múltiplos

- Fluxo de Instruções: É a sequência de instruções executadas pelo computador.
- Fluxo de Dados: É a sequência de dados sobre os quais operam as instruções.

Classificações e Terminologias

3.1. Classificação de Flynn

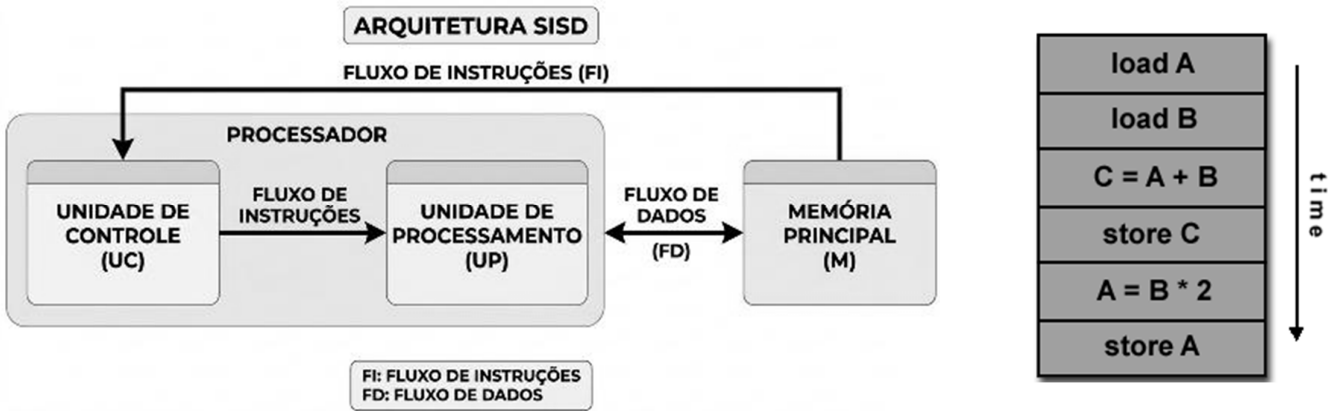
a) SISD: (*Single Instruction Single Data*)

- Executam uma única instrução por vez e com isso, acabam por manipular, também, apenas um único dado;
- Possui apenas uma unidade de processamento;
- Seguem, portanto, o modelo de *Von Neumann*.

Classificações e Terminologias

3.1. Classificação de Flynn

a) SISD: (*Single Instruction Single Data*)



Classificações e Terminologias

3.1. Classificação de Flynn

b) SIMD: (*Single Instruction Multiple Data*)

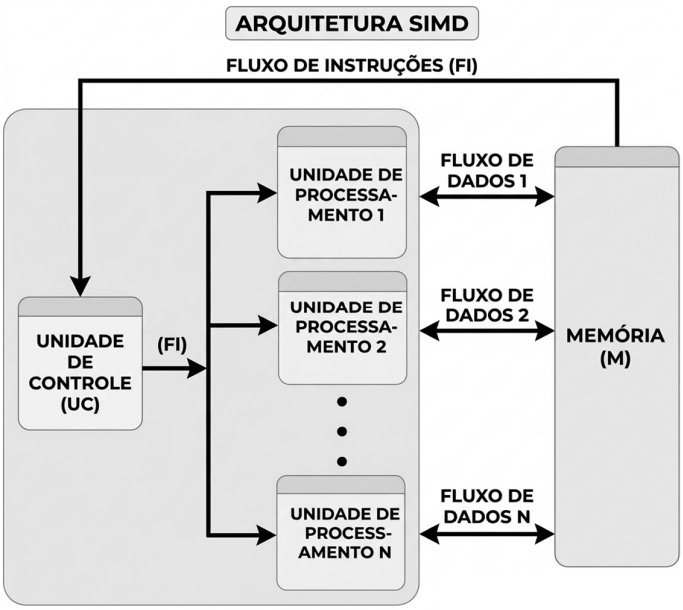
- Possui um único fluxo de instrução que opera sobre vários fluxos de dados;
- Várias unidades de processamento são supervisionados por uma única unidade de controle;
- As unidades de execução paralela estão sincronizadas;
- Tamanho reduzido da memória para programas, isto é, só precisam de uma cópia do código que está sendo executado simultaneamente;

Classificações e Terminologias

3.1. Classificação de Flynn

b) SIMD: (*Single Instruction Multiple Data*)

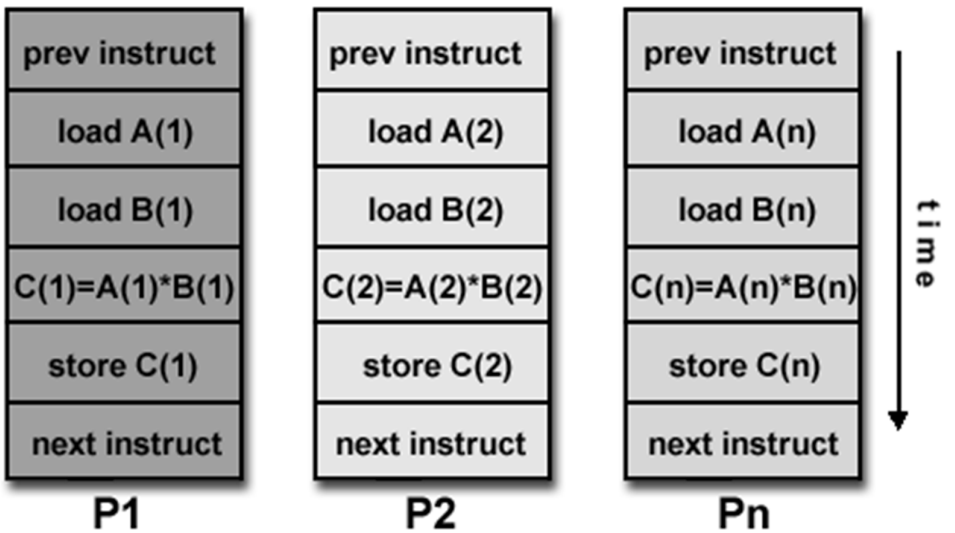
- As instruções SIMD são distribuídas em *broadcast* para todas as unidades de execução;



Classificações e Terminologias

3.1. Classificação de Flynn

b) SIMD: (*Single Instruction Multiple Data*)



Classificações e Terminologias

3.1. Classificação de Flynn

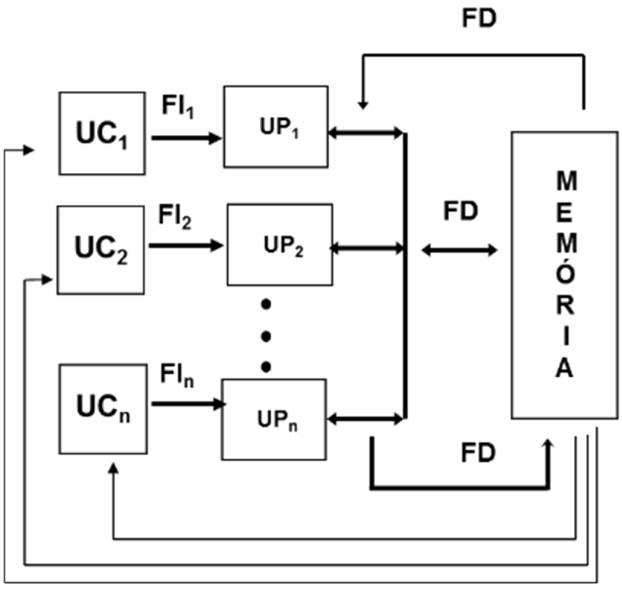
c) MISD: (*Multiple Instruction Single Data*)

- Possuem múltiplos fluxos de instruções para um único fluxo de dados;
  - ☒ Não existem máquinas desse tipo;
  - ☒ Alguns autores consideram o *PIPELINE* como um representante dessa categoria.
  - ☒ Algumas utilizações possíveis:
    - Múltiplos Filtros de frequência operando em um fluxo único de sinal;
    - Vários algoritmos de criptografia tentando quebrar uma única mensagem codificada.

Classificações e Terminologias

3.1. Classificação de Flynn

c) MISD: (*Multiple Instruction Simple Data*)



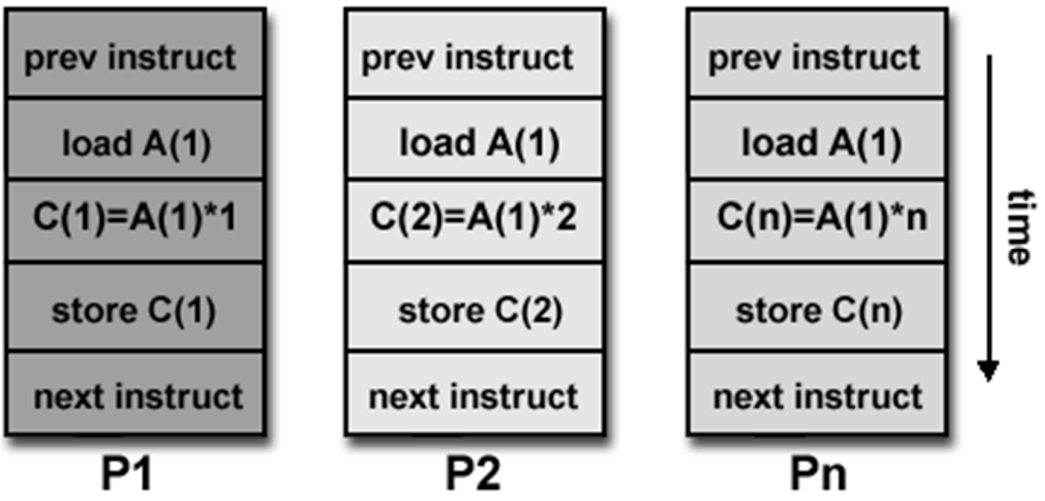
Legenda:

UC: Unidade de Controle
UP: Unidade de Processamento
M: Memória
FI : Fluxo de Instruções
FD: Fluxo de Dados

Classificações e Terminologias

3.1. Classificação de Flynn

c) MISD: (*Multiple Instruction Simple Data*)



Classificações e Terminologias

3.1. Classificação de Flynn

d) MIMD: (*Multiple Instruction Multiple Data*)

- Operam múltiplos fluxos de instruções sobre múltiplos fluxos de dados;
- A principal característica deste tipo de máquina é a existência de uma unidade de controle independente para cada processo.

✓ Duas arquiteturas:

- Memória Compartilhada;
- Memória Distribuída;

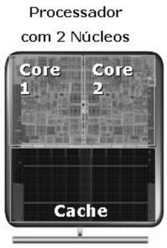
Classificações e Terminologias

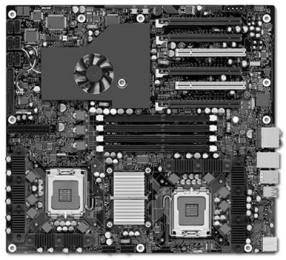
3.1. Classificação de Flynn

d) MIMD: (*Multiple Instruction Multiple Data*)



- Multicomputadores: Utilizam memória distribuída.



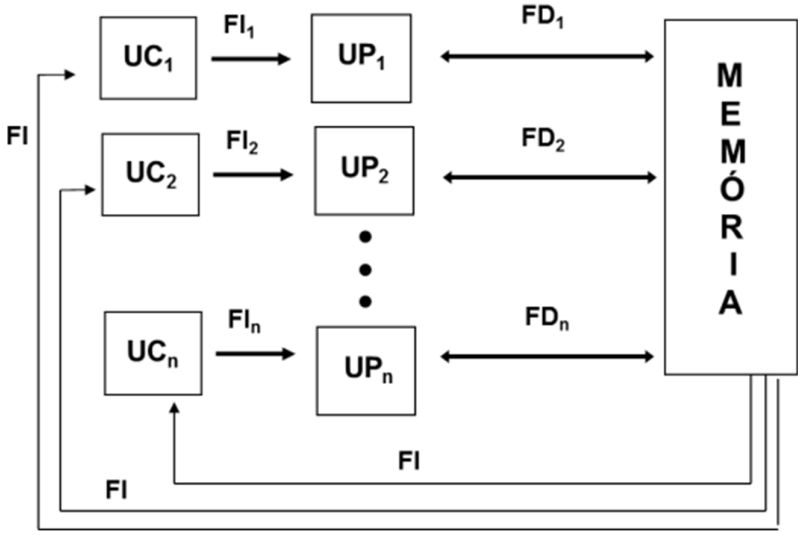


- *Multicore*/Multiprocessadores: Utilizam memória compartilhada.

Classificações e Terminologias

3.1. Classificação de Flynn

d) MIMD: (*Multiple Instruction Multiple Data*)



Legenda:

FI : Fluxo de Instruções
FD: Fluxo de Dados
UC: Unidade de Controle
UP: Unidade de Processamento
M: Memória

Classificações e Terminologias

3.1. Classificação de Flynn

d) MIMD: (*Multiple Instruction Multiple Data*)

